


```

5     habillage = "Competition"
6 )

```



2.12 Exercices

Exercice 2.1 (ACP des individus) Rappelons que le jeu de données se présente sous la forme d'une matrice $X = (x_{i,j})$, de dimensions $n \times p$, à coefficients dans $\mathbb{R}$, où n est le nombre d'individus et p celui des variables.

- L'espace $\mathbb{R}^n$ des individus d'une métrique M ;
- L'espace $\mathbb{R}^p$ des variables d'une métrique $D = \text{diag}(w_1, \dots, w_n)$ où $w_i > 0$ et $\sum_i w_i = 1$.

Nous notons $Y = (y_{i,j})$ la matrice des données centrées, et $Z = (z_{i,j})$ celle des données centrées réduites.

1. Rappeler les liens entre Y , Z et X .
2. Déterminer la matrice S^2 des variances-covariances des observations.
3. Soit u^1 un vecteur M -unitaire qui engendre le premier axe principal.

a. Montrer que l'inertie du nuage centré par rapport à cette axes est $I_{u^1} = {}^t u^1 M S^2 M u^1$.

b. Rappelons que $u^1 = \arg \max_{\|u\|_M^2=1} I_{u^1}$. Montrer que u^1 est un vecteur propre associé à la plus grande valeur propre λ_1 de $S^2 M$.

c. La première composante principale $c^1 \in \mathbb{R}^n$ est le vecteur des coordonnées des projectés M -orthogonaux des lignes de Y sur Δ_{u^1} , coordonnées dans la base (u^1) . Montrer que $c^1 = YMu^1 \in \mathbb{R}^n$.

4. Le 2e axe principal est engendré par un vecteur u^2 tel que I_{u^2} est maximale parmi les inerties expliquées par les droites Δ_u où ${}^t uMu = 1$ et ${}^t uMu^1 = 0$. Montrer que u^2 est un vecteur propre de $S^2 M$ associé à la deuxième plus grande valeur propre λ_2 de $S^2 M$.

5. En déduire une caractérisation générale des axes principaux.

6. Pour obtenir la réduction de la dimension de représentation des individus à q , il suffit de projeter M -orthogonalement les individus centrés y_i dans l'espace principal $E_q = \text{Vect}\{u^1, \dots, u^q\}$.

a. Vérifier que les coordonnées de la projection des n individus centrés sont données dans les q premières colonnes de $C = YMU$.

b. Montrer que les colonnes de C sont centrées, décorréelées et de variance la diagonale de la matrice $\Lambda = \text{diag}(\lambda_1, \dots, \lambda_r)$.

Exercice 2.2 (ACP des variables) L'ACP des individus est notée $ACP(Y, D, M)$ où:

- Y est la matrice des données
- D la matrice des poids
- M la métrique.

L'ACP des variables est par $ACP({}^t Y, M, D)$. Ainsi, la matrice à décomposer pour cette ACP est

$$YM^t YD.$$

Supposons que $rg(Y) = r$.

1. Montrer que $YM^t YD$ et $S^2 M$ ont les mêmes valeurs propres non-nulles $\lambda_1 > \dots > \lambda_r > 0$ que $S^2 M$, de vecteurs propres associés donnés par les colonnes de la matrice $F = C\Lambda^{-\frac{1}{2}}$.
2. Montrer que les colonnes de F sont D -orthonormés.
3. Montrer que la matrice des composantes principales est $C_{pv} = U\Lambda^{\frac{1}{2}}$.
4. Montrer que la matrice des facteurs principaux est $F_{pv} = U$.
5. Montrer que la part de l'inertie expliquée par les espaces principaux des deux ACP sont égales.
6. Dresser un tableau comparatif de l'ACP des variables à celle des individus.

Exercice 2.3 On dispose du classement de $n = 11$ individus sur $p = 3$ matières : math, musique et français. Le classement en math revient à numéroter les individus. Le tableau des classements selon les trois matières est donné dans la Table 2.

Matière	1	2	3	4	5	6	7	8	9	10	11
Math	6	1	4	5	3	2	9	7	8	10	11
Musique	6	1	4	5	3	2	9	7	8	10	11

Matière	1	2	3	4	5	6	7	8	9	10	11
Français	2	6	5	3	4	1	8	9	7	10	11

Les individus sont affectés du même poids.

1. Calculer le centre de gravité $\bar{x}$.
2. Calculer le tableau des données centrées Y .
3.
 - a. Réaliser l'ACP des individus.
 - b. Réaliser l'ACP des variables.
 - c. Commenter les résultats.
4. Vérifier les calculs à l'aide du logiciel [R](#) ou [Python](#).

Exercice 2.4 On considère un jeu de données $X = (x_{ij})$ constitué de deux séries statistiques quantitatives x^1 et x^2 . La matrice de variances-covariances empirique est

$$S^2 = \begin{pmatrix} 1 & \alpha \\ \alpha & 1 \end{pmatrix}$$

où $\alpha > 0$. On note $\lambda_1 \geq \lambda_2$ les deux valeurs propres de V . On munit l'espace $\mathbb{R}^2$ des individus du produit scalaire usuel.

1. Calculer λ_1 et λ_2 .
2. Calculer les deux vecteurs propres orthogonaux et unitaires u^1 et u^2 de S^2 .
3. Calculer les composantes principales c^1 et c^2 en fonction de x^1 , x^2 et éventuellement de α .
4. En déduire la moyenne et la variance de c^1 et c^2 .
5. On note C la matrice de colonnes c^1 et c^2 et V celle de colonnes u^1 et u^2 . Montrer que c^1 et c^2 sont non-corrélées.

Exercice 2.5 (Travaux pratiques) Ce TP vise à appliquer l'ACP sur le jeu de données [iris](#), qui est un ensemble de données classique en statistiques et contient les mesures en centimètres de la longueur et de la largeur des sépales et des pétales pour 50 fleurs de chacune des 3 espèces d'iris.

Objectifs

- Comprendre et appliquer l'ACP pour réduire la dimensionnalité des données.
- Visualiser les données dans le nouvel espace des composantes principales.
- Interpréter les axes principaux et les scores des composantes.

Matériel Nécessaire

- Langages [R](#) ou [Python](#) ;
- IDE: [RStudio](#) ou [jupyter](#) ;
- Les packages [FactoMineR](#) et [ggplot2](#) sous [R](#) ;
- Les librairies [scikit-learn](#), [pandas](#), [numpy](#), [matplotlib](#) sous [Python](#).

Exploration des données

1. Chargez le jeu de données [iris](#) disponible dans R.
2. Réalisez une analyse exploratoire des données :
 - Calculez les statistiques descriptives de base.
 - Créez des graphiques de dispersion pour chaque paire de variables.

Prétraitement des Données

1. Standardisez les données en centrant et réduisant les variables pour que chacune ait une moyenne de zéro et un écart type de un.
2. Vérifiez que la standardisation est correcte en vérifiant les moyennes et les écarts types post-standardisation.

ACP sur les Données Iris

1. Utilisez le package `FactoMineR` pour effectuer une ACP normée sur le jeu de données iris.
2. Extrayez et interprétez les valeurs propres : combien de composantes principales retiendriez-vous et pourquoi ?

Visualisation des Composantes Principales

1. Visualisez les deux premières composantes principales avec `ggplot2`. Utilisez les couleurs pour distinguer les espèces d'iris.
2. Que pouvez-vous déduire de cette visualisation en termes de séparation des espèces ?

Interprétation des Résultats

1. Interprétez les vecteurs propres des deux premières composantes principales : quelles variables contribuent le plus à ces composantes ?
2. Comment les résultats de l'ACP peuvent-ils être utilisés pour une analyse plus poussée, comme la classification ?

Conclusion

Rédigez un bref rapport résumant les étapes effectuées, vos observations et conclusions sur la séparabilité des espèces dans le jeu de données iris à l'aide de l'ACP.

Exercice 2.6 (Implémentation sous R ou Python) Sous R

1. Implémentez une fonction `myACP` qui réalise l'ACP sur un jeu de données.
2. Comparez vos résultats à ceux que propose le package `FactoMiner`.

Sous Python

Le module `preprocessing` de la librairie `scikit-learn` contient une classe nommée `PCA` pour réaliser les calculs essentiels de l'ACP.

1. Explorer la classe `PCA` en notant les calculs effectués.
2. Créer une classe `MyPCA` qui hérite de `PCA` pour bénéficier des calculs de cette dernière, puis étendez les fonctionnalités en implémentant les méthodes complémentaires.
3. Tester votre classe sur les données `iris` qui se trouve dans le module `datasets` de `scikit-learn`.

Analyser les données suivantes sous R ou Python.

Modèle	CYL	PUISS	LONG	LARG	POIDS	V_MAX
Alfasud TI	1350	79	393	161	870	165

Modèle	CYL	PUISS	LONG	LARG	POIDS	V_MAX
Audi 100	1588	85	468	177	1110	160
Simca 1300	1294	68	424	168	1050	152
Citroen GS Club	1222	59	412	161	930	151
Fiat 132	1585	98	439	164	1105	165
Lancia Beta	1297	82	429	169	1080	160
Peugeot 504	1796	79	449	169	1160	154
Renault 16 TL	1565	55	424	163	1010	140
Renault 30	2664	128	452	173	1320	180
Toyota Corolla	1166	55	399	157	815	140
Alfetta-1.66	1570	109	428	162	1060	175
Princess-1800	1798	82	445	172	1160	158
Datsun-200L	1998	115	469	169	1370	160
Taunus-2000	1993	98	438	170	1080	167
Rancho	1442	80	431	166	1129	144
Mazda-9295	1769	83	440	165	1095	165
Opel-Rekord	1979	100	459	173	1120	173
Lada-1300	1294	68	404	161	955	140

Exercice 2.7 Dans cet exercice, nous allons appliquer l'ACP à un jeu de données contenant les notes de $n = 15$ élèves dans quatre matières différentes : maths, physiques, français et latin, où chaque note est sur 20.

Élève	Maths	Physiques	Français	Latin
1	18	17	9	8
2	16	15	10	9
3	17	16	12	11
4	9	8	16	17
5	10	9	17	18
6	11	10	15	16
7	14	14	14	14

Élève	Maths	Physiques	Français	Latin
8	13	13	13	13
9	15	15	12	12
10	7	7	18	19
11	8	9	17	18
12	12	11	16	15
13	16	17	13	12
14	17	18	10	11
15	15	16	17	16

Les objectifs de cet exercice sont les suivants :

1. Standardisez les données et effectuez une ACP normée.
2. Combien de composantes principales faut-il retenir selon le critère de Kaiser ?
3. Interprétez les deux premières composantes principales : quels sont les contributions des variables originales dans ces composantes ?
4. Visualisez les élèves et les matières dans le premier plan principal.
5. Interprétez la position des élèves dans ce plan : y a-t-il des groupes d'élèves similaires ?